

Relatório de Progresso: Mineração de Padrões Frequentes em Acidentes em Rodovias Federais

Erik Roberto Reis Neves, Gabriel Campos Prudente, Felipe Silva Fraga Damasceno

Maio de 2026

Resumo

Este relatório intermediário documenta o progresso do Grupo 18 no projeto de Mineração de Dados sobre acidentes em rodovias federais, utilizando dados abertos da Polícia Rodoviária Federal (PRF) com recorte geográfico em Minas Gerais. Descrevemos o refinamento dos objetivos, a fundamentação metodológica baseada em CRISP-DM, os resultados preliminares da análise exploratória, a infraestrutura de pipeline implementada e o plano de experimentos para as fases de modelagem e avaliação. Os resultados experimentais completos de mineração de regras de associação serão apresentados no relatório final.

1 Introdução e Refinamento dos Objetivos

Os acidentes de trânsito em rodovias federais representam um problema de saúde pública e infraestrutura no Brasil. A PRF registra sistematicamente essas ocorrências, gerando bases de dados ricas em variáveis temporais, ambientais, viárias e de consequência. Análises univariadas são insuficientes para capturar a interação simultânea de múltiplos fatores de risco; técnicas de mineração de dados permitem descobrir padrões ocultos e correlações não triviais.

1.1 Objetivo Geral

Desenvolver um estudo completo de Mineração de Dados sobre acidentes rodoviários federais, identificando **padrões ocultos e regras de associação estatisticamente relevantes** associadas à severidade dos acidentes.

1.2 Objetivos Específicos Refinados

Com base na proposta inicial e na análise exploratória conduzida, os objetivos foram refinados da seguinte forma:

1. Identificar conjuntos frequentes de itens que caracterizem cenários de risco elevado em Minas Gerais (MG), utilizando representação transacional one-hot.
2. Gerar e analisar regras de associação com métricas de suporte, confiança, lift e conviction, priorizando padrões interpretáveis e não redundantes.
3. Segmentar a base por clustering (K-Means) como etapa **complementar**, investigando diferenças estruturais entre contextos (urbano vs. rural, perfis viários distintos).
4. Operacionalizar as diretrizes de IA responsável **Explicabilidade e Monitoramento e Avaliação** na seleção, apresentação e validação temporal das regras.

1.3 Escopo e Decisões de Recorte

O recorte analítico concentra-se em Minas Gerais sobre a base `datatran2026_agrupados_por_ocorrendia.csv` em que cada registro corresponde a uma ocorrência única de acidente. Essa granularidade foi escolhida por ser a mais natural para a representação transacional exigida pelo FP-Growth, uma vez que cada linha pode ser tratada como uma transação composta por múltiplos itens categóricos. Após filtragem por UF, o conjunto analisado totaliza 2.985 ocorrências no período considerado.

Quanto aos métodos, o FP-Growth constitui a técnica principal para extração de itemsets frequentes e geração de regras de associação. O K-Means, por sua vez, será empregado de forma complementar como etapa de segmentação prévia, permitindo investigar se padrões locais — por exemplo, em trechos urbanos versus rurais — permanecem ocultos quando se analisa apenas a base global.

2 Trabalhos Relacionados

2.1 Mineração de Padrões Frequentes

Zaki e Meira Jr. [1] descrevem o algoritmo FP-Growth e sua estrutura FP-Tree, que compacta a base transacional e evita a geração explícita de candidatos, sendo adequado para bases de alta dimensionalidade como a da PRF. Métricas clássicas — suporte, confiança, lift e conviction — são utilizadas para filtrar associações espúrias e priorizar padrões informativos.

2.2 Metodologia CRISP-DM

Wirth e Hipp [2] propõem o CRISP-DM como processo padrão para projetos de mineração de dados, estruturando o trabalho em fases iterativas: compreensão do negócio e dos dados, preparação, modelagem, avaliação e deployment. Adotamos essa estrutura para organizar o pipeline em seis notebooks reproduzíveis, o que facilita o trabalho paralelo do grupo e o rastreamento de progresso por fase.

2.3 Dados Abertos da PRF

A Polícia Rodoviária Federal disponibiliza publicamente bases consolidadas de acidentes em rodovias federais [3], com documentação sobre variáveis temporais, espaciais, ambientais e de gravidade. Essas bases têm sido utilizadas em estudos de segurança viária e análises descritivas, mas a aplicação sistemática de mineração de regras de associação multivariadas sobre recortes regionais permanece pouco explorada na literatura acadêmica do grupo.

3 Descrição da Investigação

3.1 Problema e Questões de Pesquisa

O problema central consiste em identificar **regras de associação estatisticamente significativas e não triviais** que relacionem combinações de fatores contextuais à ocorrência de acidentes de alta gravidade. Diferentemente de abordagens centradas em variáveis isoladas, buscamos padrões multivariados de coocorrência capazes de revelar estruturas latentes nos dados — isto é, combinações recorrentes de condições ambientais, temporais e viárias que aparecem de forma conjunta nos registros, e não apenas correlações marginais entre atributos individuais.

Com base na análise exploratória (Fase 2), formulamos cinco hipóteses a serem investigadas na modelagem:

1. **H1:** Combinações de {Plena Noite, Pista Simples, Zona Rural} estão associadas a maior gravidade.

2. **H2**: Finais de semana + Madrugada apresentam padrões distintos de associação.
3. **H3**: Colisões frontais e atropelamentos têm lift elevado com acidentes fatais.
4. **H4**: Condições meteorológicas adversas combinadas com tipo de pista influenciam a gravidade.
5. **H5**: Padrões de acidentes variam entre zonas urbanas e rurais.

A confirmação ou refutação dessas hipóteses mediante regras de associação será conduzida na fase de modelagem e reportada no relatório final.

3.2 Dados PRF e Recorte Geográfico

O projeto utiliza três arquivos CSV disponibilizados pela PRF (2026), selecionáveis por meio de um dicionário central no notebook de setup. A base por ocorrência (`datatran2026_agrupados_por_ocorrencia.csv`) contém 30 colunas e cerca de 23.475 registros nacionais; a base por pessoa (`acidentes2026_agrupados_por_pessoa.csv`) reúne 35 colunas e aproximadamente 64.125 registros, incluindo variáveis demográficas; e a base de todas causas e tipos (`acidentes2026_todas_causas_tipos.csv`) expande multicausas em 37 colunas e cerca de 196.099 registros. Para este estudo, adotamos a granularidade por ocorrência como dataset principal.

Após aplicar o filtro geográfico $UF = MG$, obtivemos 2.985 ocorrências e 36 colunas analíticas. Na preparação transacional, selecionamos 12 atributos categóricos — incluindo features engenheiradas como `faixa_horaria` e `gravidade_binaria` —, o que produziu inicialmente 207 itens no formato one-hot `coluna=valor`. Para evitar a explosão de itens raros ou dominantes, aplicamos filtragem de frequência entre 1% e 99%, reduzindo o conjunto final a 83 itens válidos para mineração.

3.3 Dicionário mínimo de variáveis (para leitura do relatório)

Nesta seção, resumimos as variáveis centrais utilizadas na análise exploratória e que compõem os itens transacionais empregados na mineração:

- `classificacao_acidente`: gravidade do acidente (“Sem Vítimas”, “Com Vítimas Feridas”, “Com Vítimas Fatais”).
- `tipo_acidente`: categoria do evento (o *que* ocorreu, por exemplo colisões, saída de leito carroçável, atropelamento).
- `causa_acidente`: causa atribuída (o *porquê* do evento segundo o registro, por exemplo ausência de reação, velocidade incompatível).
- `fase_dia`: fase do dia (ex.: plena noite, amanhecer, pleno dia).
- `dia_semana`: dia da semana da ocorrência.
- `condicao_meteorologica`: condição meteorológica (ex.: céu claro, chuva).
- `tipo_pista`, `tracado_via`, `sentido_via`: características da via.
- `uso_solo`: indicador binário do entorno da via no dataset de ocorrência (valores Sim/Não). Neste relatório, tratamos Sim como contexto *urbano* e Não como contexto *rural*, em linha com a leitura exploratória do grupo sobre a codificação do campo pela PRF.

- **faixa_horaria**: discretização do horário em faixas (madrugada/manhã/tarde/noite), derivada de **horario**.
- **fim_de_semana**: indicador derivado de **dia_semana**.
- **gravidade_binaria**: indicador derivado para separar acidentes fatais vs. não fatais, usado para apoiar filtros e comparações.

3.4 Resultados Preliminares da EDA

A Tabela 1 resume a distribuição da variável-alvo. Observa-se um desbalanceamento marcante: apenas 7,1% dos acidentes são classificados como fatais, enquanto a grande maioria (79,3%) resulta em vítimas feridas. Esse perfil de classes impactará diretamente a calibração do suporte mínimo no FP-Growth, pois padrões associados à gravidade fatal tenderão a apresentar suportes mais baixos e exigirão atenção especial na interpretação dos resultados.

Tabela 1: Distribuição da classificação de gravidade (MG, $n = 2.985$).

Classificação	Proporção
Com Vítimas Feridas	79,3%
Sem Vítimas	13,6%
Com Vítimas Fatais	7,1%

A análise de associação entre variáveis categóricas e a gravidade, conduzida via Cramér's V , indicou que **tipo_acidente** ($V = 0,399$), **causa_acidente** ($V = 0,325$) e **tracado_via** ($V = 0,175$) são os atributos mais fortemente associados à classificação do acidente. Esses resultados reforçam a relevância de incluir tais variáveis na representação transacional e orientam a expectativa de que regras envolvendo tipologia e causa do evento tendam a ser mais informativas do que combinações puramente temporais ou geográficas.

Como ler os gráficos a seguir. Em gráficos **normalizados**, cada barra/linha representa uma categoria (por exemplo, um tipo de acidente) e soma 100%. Esses gráficos permitem comparar *composição* de gravidade entre categorias, mas não substituem análises de volume (frequências absolutas). Em todas as interpretações, enfatizamos que associação estatística não implica causalidade.





Figura 1: Resultados preliminares da análise exploratória.

Tabela 2: Top tipos de acidente (MG).


Tipo	Frequência	%
Saída de leito carroçável	628	0.210
Colisão traseira	518	0.174
Tombamento	323	0.108
Colisão transversal	278	0.093
Colisão com objeto	261	0.087
Colisão lateral mesmo sentido	259	0.087
Colisão frontal	194	0.065
Atropelamento de Pedestre	116	0.039
Incêndio	87	0.029
Queda de ocupante de veículo	86	0.029
Outros	235	0.079

Tipos de acidente (Top 10 + Outros)

A Tabela 2 lista os tipos de acidente mais frequentes no recorte (MG). A Figura 2a mostra a distribuição absoluta, enquanto a Figura 2b mostra a composição de gravidade **normalizada** por tipo, evidenciando como a proporção de fatalidade varia entre categorias.



(a) Top tipos (frequência).



(b) Gravidade por tipo (normalizado).

Figura 2: Tipos de acidente no recorte MG (Top 10 + Outros).

Causas do acidente (Top 12 + Outros)

Complementarmente, analisamos `causa_acidente`, que representa a causa atribuída no registro (diferente do *tipo* do evento). A Tabela 3 sumariza as causas mais frequentes, e a Figura 3b apresenta a composição de gravidade normalizada por causa.

Tabela 3: Top causas de acidente (MG).

Causa	Frequência	%
Ausência de reação do condutor	505	0.169
Reação tardia ou ineficiente do condutor	385	0.129
Velocidade Incompatível	355	0.119
Acessar a via sem observar a presença dos outros veículos	206	0.069
Demais falhas mecânicas ou elétricas	160	0.054
Condutor Dormindo	150	0.050
Condutor deixou de manter distância do veículo da frente	149	0.050
Chuva	117	0.039
Ingestão de álcool pelo condutor	98	0.033
Manobra de mudança de faixa	87	0.029
Transitar na contramão	79	0.026
Ultrapassagem Indevida	66	0.022
Outros	628	0.210






Figura 3: Causas do acidente no recorte MG (Top 12 + Outros).

Condições de via e perfil temporal

A Figura 4a resume como a composição de gravidade varia entre os tipos de pista mais frequentes, enquanto a Figura 4b mostra o percentual de acidentes fatais em janelas `dia_semana` $\times$ `fase_dia`, permitindo comparar *risco relativo* de fatalidade sem confundir com volume total de ocorrências.



(a) Tipo de pista × gravidade (proporção).



(b) % de fatais por dia × fase do dia.

Figura 4: Condições de via e perfil temporal no recorte MG.

Foram produzidas 17 visualizações exploratórias no notebook 02, abrangendo distribuições temporais, geográficas, categóricas e correlações entre variáveis numéricas. Conjuntamente, esses achados subsidiam a seleção de atributos transacionais, a calibragem de parâmetros de mineração e a formulação das hipóteses H1–H5 descritas acima.

4 Metodologia Detalhada (CRISP-DM)

O pipeline do projeto foi organizado em seis notebooks sequenciais, alinhados às fases do CRISP-DM. A configuração global — caminhos, dataset ativo, filtros e seleção de colunas — concentra-se no notebook 01_`setup_e_carregamento.ipynb` e é reutilizada pelos demais, garantindo consistência e permitindo trocar granularidade ou recorte geográfico alterando apenas constantes centrais, sem reescrever a lógica de cada etapa.

A Tabela 4 resume os parâmetros de configuração adotados na execução atual do pipeline.

Tabela 4: Configuração global do pipeline (notebooks 01 e 03).

Parâmetro	Valor / descrição
ACTIVE_DATASET	por_ocorrenci → datatran2026_agrupados_por_ocorrenci.csv
FILTRO_UF	MG
SEP / ENCODING	; / latin-1 (ISO-8859-1)
DATA_DIR	../data/
PROCESSED_DIR	../data/processed/
OUTPUT_DIR	../outputs/
COLUNAS_CATEGORICAS_COMUNS	semana, causa_acidente, tipo_acidente, classificacao_acidente, fase_dia, sentido_via, condicao_meteorologica, tipo_pista, tracado_via, uso_solo
COLUNAS_TRANSACIONAIS2	colunas: 10 categóricas comuns + faixa_horaria, fim_de_semana, gravidade_binaria
Filtro de itens	frequência ∈ [1%, 99%] → 207 itens → 83 itens finais

A Figura 5 apresenta o fluxo de dados entre os notebooks e os artefatos intermediários gerados.

Pipeline CRISP-DM — Acidentes em Rodovias Federais (MG)




Figura 5: Pipeline CRISP-DM implementado: fluxo de dados da PRF até visualização.

4.1 Business & Data Understanding — Concluído

Na fase de Business and Data Understanding, os notebooks `01_setup_e_carregamento.ipynb` e `02_analise_exploratoria.ipynb` estabelecem a infraestrutura de carregamento e a compreensão inicial dos dados. O notebook 01 define o dicionário `DATASETS`, a variável `ACTIVE_DATASET` e as funções reutilizáveis de carregamento e concatenação com filtro por UF, permitindo alternar entre as três granularidades disponíveis sem modificar o código analítico downstream.

O notebook 02 concentra a análise exploratória completa: avaliação de qualidade dos dados (valores ausentes e inconsistências), distribuições univariadas e bivariadas, análise temporal e geográfica, cálculo de Cramér’s V entre variáveis categóricas e gravidade, além da produção de 17 visualizações. Ao final desta fase, formulamos as hipóteses H1–H5 e documentamos implicações práticas para a mineração, como o impacto do desbalanceamento de classes sobre o suporte mínimo.

4.2 Data Preparation — Concluído

A fase de Data Preparation, implementada no notebook `03_preparacao_dados.ipynb`, transforma o dataset bruto em uma representação adequada ao FP-Growth. Inicialmente, tratamos valores ausentes preenchendo categorias com “Não Informado” e padronizamos strings e a conversão numérica do campo `km`. Em seguida, criamos features derivadas — `mes`, `faixa_horaria`, `fim_de_semana`, `gravidade_binaria` e `faixa_km` — que enriquecem a granularidade temporal e espacial da base.

A representação transacional converte cada ocorrência em um conjunto de itens binários no formato `coluna=valor`. Após a codificação one-hot, aplicamos filtragem de itens com frequência inferior a 1% ou superior a 99%, reduzindo a dimensionalidade de 207 para 83 itens. Os artefatos processados são persistidos em `data/processed/` (`df_limpo.pkl` e `transacional.pkl`) para consumo pelos notebooks de modelagem e avaliação.

4.3 Modeling — Planejado

A fase de Modeling será conduzida no notebook `04_modelagem.ipynb`. A infraestrutura de mineração já foi montada e validada em execução piloto; os experimentos formais previstos incluem mineração global via FP-Growth sobre a base transacional completa, com `min_support` calibrado a partir do desbalanceamento observado na EDA. A partir dos itemsets frequentes, geraremos regras de associação filtrando associações com lift superior a 1, ordenando-as por relevância e extraíndo separadamente aquelas cujo consequente indica gravidade fatal.

Como etapa complementar, aplicaremos K-Means sobre atributos categóricos codificados e padronizados, determinando o número de clusters por meio do método do cotovelo e do silhouette score. A mineração será então repetida de forma independente em cada segmento, buscando capturar padrões locais que possam estar mascarados na análise global. Por fim, executaremos FP-Growth em janelas mensais para avaliar a estabilidade temporal dos padrões identificados.

4.4 Evaluation — Planejado

A fase de Evaluation será distribuída entre os notebooks `05_avaliacao_ia_responsavel.ipynb` e `06_visualizacao_resultados.ipynb`. Nela, consolidaremos tabelas comparativas das regras mais relevantes, traduziremos padrões selecionados para linguagem natural e analisaremos a estabilidade temporal das associações entre períodos distintos. Também incluiremos disclaimers explícitos sobre a distinção entre correlação e causalidade, além de produzir visualizações e exportações em formatos compatíveis com o relatório final (LaTeX, Markdown e figuras em alta resolução).

5 Estratégia de Avaliação

5.1 Métricas de Regras de Associação

Cada regra de associação $A \rightarrow B$ será avaliada por meio de métricas clássicas da literatura. O **suporte** mede a frequência conjunta de $A \cup B$ na base; a **confiança** expressa $P(B | A)$, indicando a probabilidade condicional do consequente dado o antecedente; e o **lift** compara a confiança observada com a esperada sob independência estatística, de modo que valores superiores a 1 indicam associação positiva. Complementarmente, **conviction** e **leverage** serão utilizados para detectar dependências assimétricas que podem passar despercebidas quando se considera apenas confiança e lift.

Além das métricas quantitativas, adotaremos critérios de seleção orientados à qualidade interpretativa das regras. Regras redundantes — aquelas com o mesmo consequente e antecedentes sobrepostos — serão removidas, priorizando-se padrões com antecedente de até três itens. Regras triviais, caracterizadas por lift próximo de 1 ou suporte extremo, serão excluídas para evitar a apresentação de associações estatisticamente fracas ou demasiadamente óbvias.

5.2 Diretriz 1: Explicabilidade (Operacionalização Prevista)

A diretriz de explicabilidade é pertinente neste projeto porque a mineração de regras de associação pode produzir um volume elevado de padrões, nem todos necessariamente úteis ou compreensíveis. No domínio de segurança viária, interpretações equivocadas — como atribuir causalidade a uma simples coocorrência estatística — podem levar a conclusões socialmente inadequadas. Por isso, os resultados precisam ser comunicados de forma clara, acompanhados de métricas e limitações explícitas.

A operacionalização prevista seguirá quatro passos integrados ao pipeline de avaliação. Primeiramente, filtraremos regras com antecedentes curtos (até três itens), favorecendo padrões de leitura direta. Em seguida, removeremos redundâncias, mantendo a formulação mais simples quando duas regras apresentarem confiança similar. Cada regra selecionada será traduzida para linguagem natural, acompanhada de suporte, confiança e lift. Por fim, incluiremos um disclaimer explícito de que associação estatística não implica relação causal.

Essa abordagem melhora a comunicabilidade dos resultados, mas impõe trade-offs relevantes. Ao priorizar simplicidade, corremos o risco de descartar padrões complexos potencialmente importantes; por isso, os critérios de filtragem deverão ser calibrados com cuidado para não eliminar associações substantivas.

5.3 Diretriz 2: Monitoramento e Avaliação (Operacionalização Prevista)

A diretriz de monitoramento e avaliação é pertinente porque os fatores associados à gravidade dos acidentes podem variar ao longo do tempo em resposta a mudanças de infraestrutura, legislação, fluxo de veículos e políticas de fiscalização. Uma regra identificada em determinado intervalo temporal pode, portanto, ser transitória e não generalizável a outros períodos.

Para incorporar essa diretriz, executaremos FP-Growth em janelas temporais mensais e compararemos os conjuntos de regras obtidos em cada período. Calcularemos a recorrência de cada regra ao longo dos meses e classificaremos os padrões como **estáveis** quando aparecerem em pelo menos 50% dos períodos analisados, ou como **transitórios** quando surgirem em menos de 30%. Para as regras estáveis, documentaremos a evolução de lift e confiança ao longo do tempo.

Essa estratégia torna a análise mais robusta frente a variações contextuais, mas aumenta a complexidade experimental. A subdivisão temporal reduz o volume de registros por janela, o que dificulta a identificação de padrões sobre acidentes fatais — classe minoritária — exigindo equilíbrio entre granularidade temporal e confiabilidade estatística.

6 Plano de Experimentos

6.1 Experimento 1: Mineração Global e Grid de Parâmetros

O primeiro experimento busca identificar itemsets frequentes e regras de associação globais, além de calibrar os hiperparâmetros da mineração. Para isso, variaremos sistematicamente `min_support` em $\{0,01, 0,03, 0,05, 0,10\}$, `min_confidence` em $\{0,3, 0,5, 0,7\}$ e `min_lift` em $\{1,0, 1,5, 2,0\}$, totalizando 36 combinações. Para cada configuração, registraremos o número de itemsets, o número de regras geradas, a quantidade de regras associadas à gravidade e o tempo de execução do FP-Growth. As métricas de saída incluirão a distribuição de lift entre as regras retidas e o custo computacional por combinação de parâmetros.

6.2 Experimento 2: Clustering + Mineração por Segmento

O segundo experimento visa capturar padrões locais que possam estar mascarados na análise global. Após codificar os atributos categóricos e padronizá-los com `StandardScaler`, determinaremos o número de clusters k por meio do método do cotovelo e do silhouette score, explorando $K \in [2, 9]$. Com o K-Means aplicado, executaremos FP-Growth de forma independente em cada segmento e compararemos as regras locais com as globais, investigando em particular a hipótese H5 sobre diferenças entre contextos urbanos e rurais.

6.3 Experimento 3: Estabilidade Temporal

O terceiro experimento avalia a robustez temporal das regras, em consonância com a diretriz de Monitoramento e Avaliação. A base será segmentada por mês a partir de `data_inversa`, executando-se FP-Growth em cada janela com no mínimo 100 registros. Os conjuntos de regras serão então comparados entre períodos, classificando-se cada padrão quanto à estabilidade ou transitividade ao longo do tempo.

6.4 Experimento 4: Visualizações e Exportação

O quarto experimento consolida o material para o relatório final. Prevê-se a produção de pelo menos dez visualizações — incluindo distribuição de suporte dos itemsets, ranking de regras por lift, scatter $\text{suporte} \times \text{confiança}$, rede de regras, evolução temporal e perfis de cluster — em resolução de 300 dpi. Paralelamente, exportaremos tabelas de regras selecionadas em formatos LaTeX e Markdown, integrando-as à redação do documento final.

7 Cronograma até 30/06/2026

As fases de setup, análise exploratória e preparação dos dados (Fases 1–3 do CRISP-DM) foram concluídas entre abril e maio de 2026. O presente relatório de progresso consolida esse avanço e detalha o plano experimental para as etapas restantes. A Tabela 5 apresenta a distribuição das atividades previstas até a entrega do relatório final, em 30/06/2026.

Tabela 5: Cronograma de execução restante.

Atividade	Período	Status
Setup, EDA e preparação (Fases 1–3)	Abr–Mai/2026	Concluído
Relatório de Progresso	Até 01/06/2026	Em entrega
Modelagem global + grid (Exp. 1)	01–10/06/2026	Planejado
Clustering + mineração local (Exp. 2)	10–15/06/2026	Planejado
Estabilidade temporal (Exp. 3)	15–20/06/2026	Planejado
Avaliação IA responsável + visualizações (Exp. 4)	20–25/06/2026	Planejado
Redação do Relatório Final	25–30/06/2026	Planejado

Referências

- [1] ZAKI, M. J.; MEIRA JR, W. *Data Mining and Machine Learning: Fundamental Concepts and Algorithms*. 2nd ed. Cambridge University Press, 2020.
- [2] WIRTH, R.; HIPPE, J. CRISP-DM: Towards a standard process model for data mining. In: *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 2000.
- [3] BRASIL. Polícia Rodoviária Federal. **Dados Abertos da PRF**. Brasília, 2026. Disponível em: <https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf>.